

# 1 Метод главных компонент

## 2 Метод опорных векторов

### Введение

В данном разделе рассмотрены основные понятия метода опорных векторов и алгоритм его работы. Определения терминов, используемых в данной работе.

1. Гиперплоскость – это  $(n - 1)$ -мерная подплоскость в  $n$ -мерном евклидовом пространстве, которая разделяет пространство на две отдельные части [1].
2. Ядро – это функция, которая вычисляет точечное произведение двух векторов в высокоразмерном пространстве [2].
3. Радиальные базисные функции – это класс функций, которые используются в нейронных сетях для аппроксимации и интерполяции данных [3].

### Основная часть

Метод опорных векторов – линейный алгоритм, который используется в задачах классификации и регрессии. Суть алгоритма – найти линию или гиперплоскость, разделяющую данные на классы.

Изначально метод опорных векторов работает как линейный классификатор, способный решать только задачи, где классы данных можно разделить прямой линией. Однако при использовании нелинейных ядер, метод опорных векторов способен преобразовывать исходные данные в пространство более высокой размерности, где можно найти оптимальную разделяющую гиперплоскость [4]. Некоторые из популярных ядер метода опорных векторов:

- линейное ядро (преобразует данные в ту же размерность без изменений);

- полиномиальное ядро (преобразует данные в более высокую размерность с использованием полиномиальной функции);
- радиальное базисное функциональное ядро (преобразует данные в бесконечно высокую размерность с использованием радиальной базисной функции).

Пример. На рисунке 2.1 изображен набор данных, который необходимо классифицировать и отделить квадраты от треугольников. Существует бесконечное количество линий, способных разделить эти два класса. Основная цель в поставленной задаче – найти оптимальную из них.




Рисунок 2.1 – Исходные данные

На рисунке 2.2 изображены два варианта разделения на классы.




Рисунок 2.2 – Варианты разделяющих линий

Сплошная линия проходит слишком близко к классам треугольников и квадратов. Несмотря на то, что она верно классифицировала все объекты текущего набора данных, она не будет генерализованной, не будет так же хорошо разграничивать незнакомый набор данных. Поэтому в данном случае оптимальный выбор – прерывистая линия [4].

Основные этапы метода опорных векторов.

1. Подготовка обучающего набора данных, состоящего из пар (вектор признаков, метка класса).
2. Выбор ядра и настройка параметров модели.
3. Минимизация функции потерь с использованием оптимизационных методов для нахождения гиперплоскости, максимально разделяющей классы.
4. Нахождение опорных векторов (опорные векторы – точки данных, лежащие на границах зазора между классами).
5. Определение гиперплоскости: гиперплоскость строится для максимизации зазора между классами с учетом опорных векторов и параметров ядра.

6. Оценка обобщающей способности модели на тестовой выборке для проверки ее работоспособности на новых данных.

### 3 Алгоритм Виолы-Джонса

Метод Виолы — Джонса — алгоритм, позволяющий обнаруживать и распознавать лица на изображениях и видеопоследовательностях в режиме реального времени [5]. Данный метод основан на использовании следующих принципов:

#### 1) Интегральное представление изображения

Представим исходное изображение в виде матрицы, каждый элемент которой содержит значение интенсивности пикселя. Интегральное представление изображения формируется путем создания новой матрицы, размерность которой совпадает с матрицей исходного изображения. В каждом элементе данной матрицы хранится сумма интенсивностей всех пикселей исходного изображения, находящихся левее и выше текущего пикселя в исходной матрице [6], т. е. элементы новой матрицы рассчитываются по следующей формуле:

$$L(x, y) = \sum_{i=0, j=0}^{i \leq x, j \leq y} I(i, j), \quad (3.1)$$

где  $I(i, j)$  — значение элемента матрицы исходного изображения,  $L(x, y)$  — значение элемента матрицы интегрального изображения.

Особенностью интегрального представления является возможность вычисления суммы интенсивностей пикселей внутри произвольных прямоугольных областей [6]. Рассмотрим следующий пример, где искомой областью является прямоугольник  $ABCD$ :

Сумма интенсивностей пикселей, лежащих внутри области  $ABCD$ , будет вычисляться по следующей формуле:

$$F(ABCD) = F(A) + F(D) - F(B) - F(C), \quad (3.2)$$

где  $F(X)$  — суммы интенсивностей пикселей внутри прямоугольной области  $X$ .

Таким образом, для вычисления суммы интенсивностей пикселей внут-




Рисунок 3.1 – Расчет суммы интенсивностей пикселей в прямоугольнике  $ABCD$

ри произвольных прямоугольных областей требуется четыре обращения к матрице интегрального представления изображения.

## 2) Признаки Хаара

Для выделения областей изображения, которые наиболее вероятно содержат нужные объекты, используются признаки Хаара. Признак Хаара — результат сравнения смежных прямоугольных областей изображения путем вычисления разности сумм интенсивностей пикселей соответствующих прямоугольников [7]. В методе Виолы — Джонса используются три вида данных признаков: «два прямоугольника», «три прямоугольника», «четыре прямоугольника» [5] (рис. 3.2 [8]).




Рисунок 3.2 – Признаки Хаара

Значение каждого признака вычисляется по следующей формуле:

$$F = X - Y, \quad (3.3)$$

где  $X$  - сумма интенсивностей пикселей, находящихся в светлой области признака,  $Y$  - сумма интенсивностей пикселей, находящихся в

темной области признака.

Для вычисления данных сумм интенсивностей пикселей за константное время используется интегральное представление изображения.

### 3) Алгоритм AdaBoost

Для прогнозирования категории, к которой относится входной объект, в машинном обучении используется модель, называемая классификатором [9]. Слабый (или простой) классификатор — это классификатор, который решающий задачу классификации чуть лучше, чем случайное угадывание [10], т. е. вероятность ошибки меньше 50%.

Для повышения точности аналитических моделей используется бустинг (англ. boosting) — последовательная композиция алгоритмов машинного обучения, в которой каждый следующий алгоритм стремится компенсировать недостатки композиции всех предыдущих алгоритмов [6]. В методе Виолы — Джонса в качестве бустинга выбран алгоритм AdaBoost, в ходе выполнения которого формируется сложный классификатор, состоящий из набора простых и имеющих меньшую вероятность ошибки, чем у каждого слабого классификатора по отдельности:

$$a_s(x) = \sum_{i=1}^n b_i * a_i(x), \quad (3.4)$$

где  $x$  — изображение,  $a_s(x)$  — сложный классификатор,  $a_i(x)$  — слабый классификатор,  $b_i$  — весовой коэффициент соответствующего слабого классификатора.

Основные этапы работы алгоритма AdaBoost [5]:

- Инициализация весов объектов обучающего набора одинаковым значением;
- Для каждой итерации алгоритма на основе сравнения ошибок классификации выбирается слабый классификатор, который наилучшим образом разделяет обучающий набор с учетом текущих весов объектов;



- Для каждого выбранного классификатора вычисляется его ошибка и вес, отражающий точность разделения объектов;
- Обновление весов объектов таким образом, чтобы неправильно классифицированные объекты получили больший вес на следующей итерации;
- Формирование сложного классификатора на основе слабых классификаторов и их весов.

Таким образом, в ходе выполнения данного алгоритма путем исключения большинства имеющихся признаков выбираются наиболее подходящие для конкретного объекта, в результате чего формируется классификатор с критическими признаками.

В качестве классификаторов в методе Виолы — Джонса используются вышеописанные признаки Хаара. Для каждого признака выбирается соответствующий порог для бинарной классификации объектов, т. е. для определения того, какие значения признака считаются положительными, а какие — отрицательными. Выбор оптимального порога осуществляется таким образом, чтобы минимизировать ошибку классификации, учитывая веса объектов в процессе обучения алгоритма.

- 4) Каскадная структура классификаторов - последовательное объединение усложняющихся классификаторов в каскадную структуру (рис. 3.3 [8]) [5]. Данная структура повышает скорость обнаружения объектов, фокусируя свою работу на наиболее информативных областях изображения [6]. Это достигается тем, что каскад пытается отсеять как можно больше отрицательных экземпляров на самом раннем этапе: количество вычисленных признаков для анализа отрицательных областей должно быть значительно меньше, чем количество признаков, вычисленных для положительных областей. Следовательно, более сложные классификаторы применяются только к тем областям, которые уже прошли отсев более простыми классификаторами, что экономит ресурсы и улучшает производительность системы.

- 5) Сканирующее окно




Рисунок 3.3 – Каскадная структура классификаторов

Для выделения областей, в которых могут находиться нужные объекты, используется сканирующее окно — перемещаемая прямоугольная активная область, в которой осуществляется поиск объектов [11]. Данный подход включает в себя пошаговый анализ различных прямоугольных подокон изображения, взятых с различными смещениями и масштабами. Впоследствии для каждой такой области применяются вышеописанные каскады классификаторов, которые оценивают, соответствует ли содержимое подокна определенным критериям.

Таким образом, схему работы метода Виолы — Джонса можно представить в следующем виде:

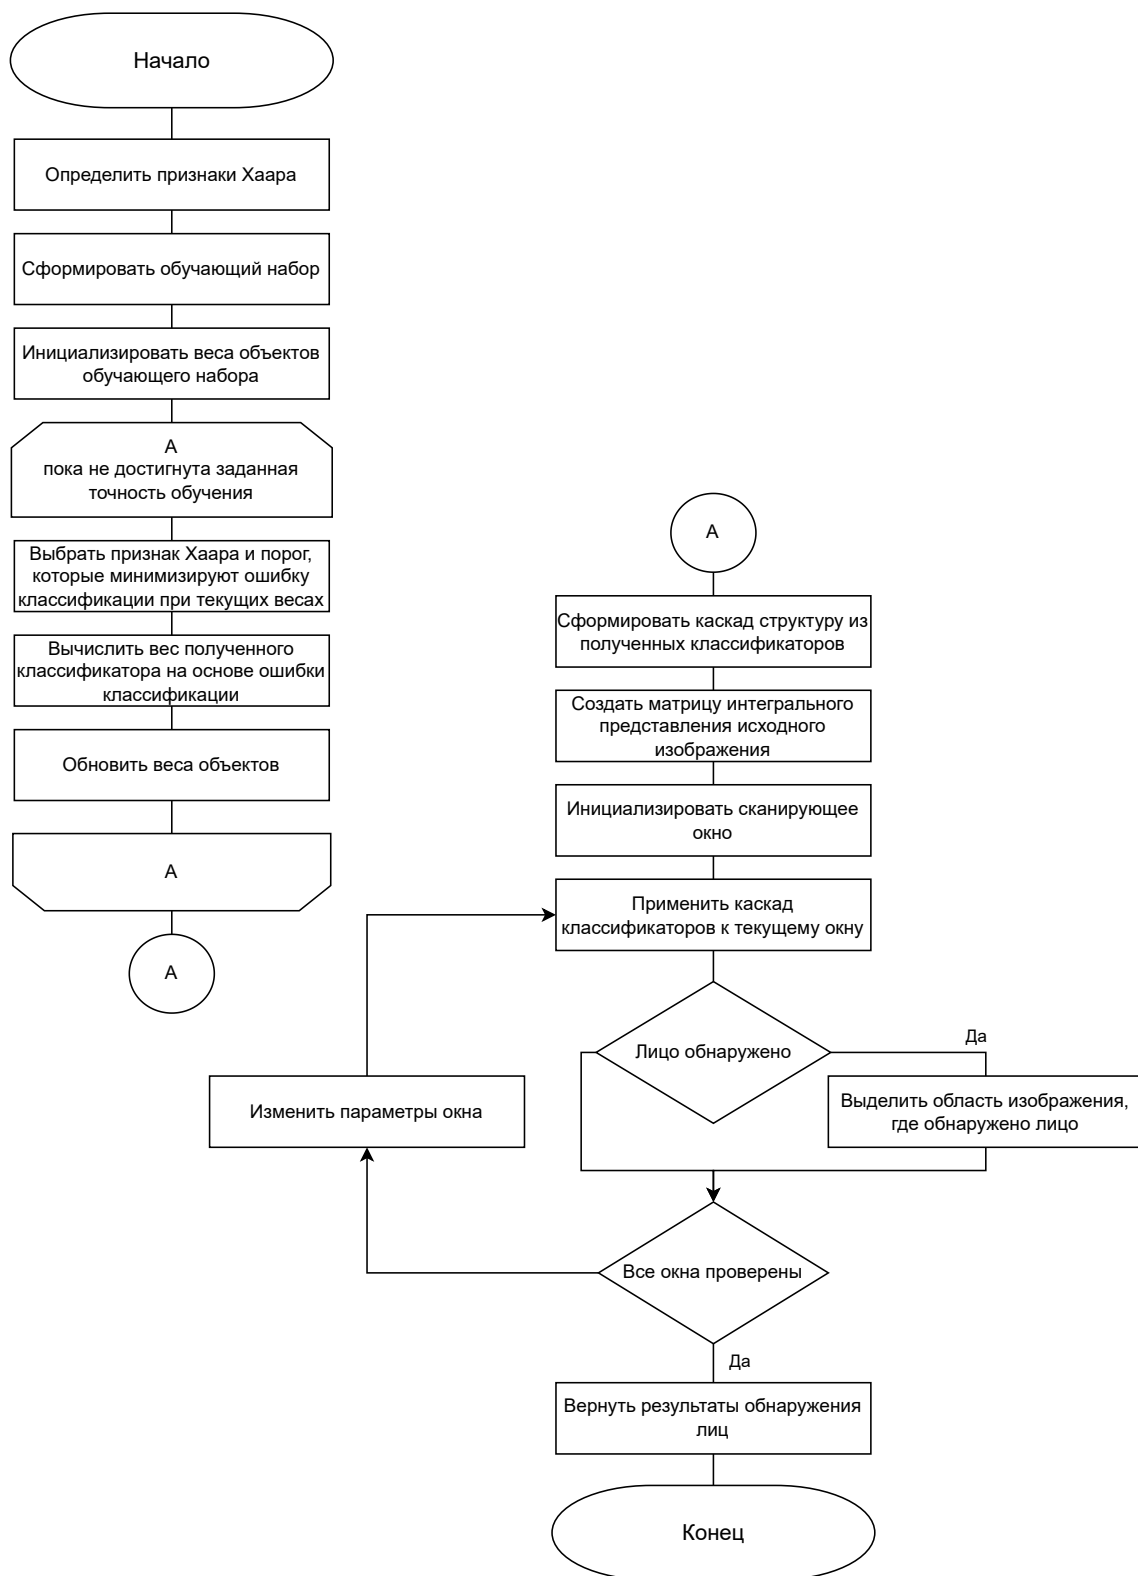


Рисунок 3.4 – Схема работы метода Виолы — Джонса

## 4 Метод гибкого сравнения на графах

Метод гибкого сравнения на графах – метод обработки изображений и распознавания образов, который используется для нахождения соответствия между двумя изображениями, учитывая возможные искажения, изменение масштаба и повороты [12].

Данный метод является одним из способов распознавания лиц. Лица представлены в виде графов со взвешенными вершинами и ребрами[13]. Во время распознавания один из графов – константный(эталонный), в то время как другой изменяется(деформируется) с целью наилучшей подгонки к первому.

В данном методе графы могут представлять собой как прямоугольную решетку (рис. 4.1.а), так и структуру, образованную антропометрическими точками лица(рис. 4.1.б).




Рисунок 4.1 – Пример структуры графа для распознавания лиц  
а)Регулярная решетка;  
б)Граф на основе антропометрических точек лица.

Частотное содержимое изображения — характеристика, показывающая насколько быстро меняется яркость или цвет в различных частях изображения [14].

Фильтр Габора — фильтр, который анализирует, присутствует ли какое-либо конкретное частотное содержимое в изображении в различных направлениях в области вокруг точки или области анализа. Данный фильтр представляет собой синусоидальную плоскую волну(рис. 4.2).[15]




Рисунок 4.2 – Пример синусоидальной плоской волны.

Свертка – операция вычисления нового значения интенсивности, степени яркости светлых пикселей по сравнению с более темными тонами, заданного пикселя, при котором учитываются значения окружающих его соседних пикселей.

В некоторой локальной области вершины графа вычисляют значения путем свертки значений яркости пикселей с набором(рис. 4.3) фильтров Габора(рис. 4.4).




Рисунок 4.3 – Набор фильтров Габора.




Рисунок 4.4 – Пример свертки изображения лица с фильтрами Габора.

### **Алгоритм распознавания лица:**

- 1) Происходит деформация графа путем смещения каждой из его вершин на некоторое расстояние в различных направлениях относительно его исходного местоположения(рис. 4.5);
- 2) Выбирается такая позиция, при которой разница между значениями в вершине деформируемого графа и соответствующей ей вершине эталонного графа будет минимальной;
- 3) Данная операция выполняется поочередно для всех вершин графа, пока не будет достигнуто наименьшее суммарное различие между признаками этих графов;
- 4) Данная процедура деформации выполняется для всех эталонных лиц, заложенных в базу данных системы. Результат распознавания – эталон с наименьшим суммарным различием.



Рисунок 4.5 – Пример деформации графа.

# Список используемых источников

1. А. В. Конюх, В. В. Косьянчук, С. В. Майоровская, О. Н. Поддубная, Е. И. Шилкина. Сборник задач и упражнений по высшей математике для студентов экономических специальностей : учеб.-метод. пособие : в 2 ч. Ч. 1. Минск : БГЭУ, 2021, 2021. с. 159.
2. Искусственный интеллект: Введение в метод опорных векторов (SVM) и его применение в реальных задачах. [Электронный ресурс] Режим доступа: [nauchniestati.ru/spravka/metod-opornyh-vektorov-svm/?ysclid=lqjqjwkhik266674310](http://nauchniestati.ru/spravka/metod-opornyh-vektorov-svm/?ysclid=lqjqjwkhik266674310).
3. Использование радиальных базисных функций в нейронных сетях: эффективный подход к обработке данных. [Электронный ресурс] Режим доступа: [nauchniestati.ru/spravka/radialnye-bazisnye-funkczii/?ysclid=lqjsghtklg734833904](http://nauchniestati.ru/spravka/radialnye-bazisnye-funkczii/?ysclid=lqjsghtklg734833904).
4. С.А. Левчук, А.А. Якименко. Исследование характеристик алгоритмов распознавания лиц // Сборник научных трудов НГТУ. 2018. Т. 3-4, № 93. С. 47–49.
5. Jones M.J. Viola P. Rapid Object Detection using a Boosted Cascade of Simple Features. — IEEE Conf. on Computer Vision and Pattern Recognition. 2001.
6. Спицын В.Г. Буй Тхи Тху Чанг Фан Нгок Хоанг. Распознавание лиц на основе применения метода Виолы-Джонса, Вейвлет-преобразования и метода главных компонент. — Известия Томского политехнического университета. Инжиниринг георесурсов. 2012.
7. Левчук С.А. Якименко А.А. Исследование характеристик алгоритмов распознавания лиц. — Сборник научных трудов НГТУ. 2018.
8. Эрман Е.А. Мамдух Мохаммед Гомаа Мохаммед. Метод обнаружения лиц на изображении с использованием комбинации метода Виолы Джонса и алгоритмов определения цвета кожи. — Вестник Астраханского государственного технического университета. Серия: Управление, вычислительная техника и информатика. 2015.

9. Murphy Kevin P. Machine learning : a probabilistic perspective. — Cambridge, Mass. : MIT Press. 2012.
10. Bishop Christopher M. Pattern recognition and machine learning. — Springer. 2006.
11. Новиков А.С. Фокин А.Г. Чубукина Т.С. Оптимизация распознавания объекта на изображении методом адаптивного движения сканирующего окна. — Известия Тульского государственного университета. Технические науки. 2015.
12. L. Wiskott JM. Fellous N. Kruger. Intelligent Biometric Techniques in Fingerprint and Face Recognition. 1999. С. 355–396.
13. WenYi Zh, Rama Chellap Imagebased Face Recognition. Режим доступа: [http://www.face-rec.org/interesting-papers/general/chapter\\_figure.pdf](http://www.face-rec.org/interesting-papers/general/chapter_figure.pdf).
14. Robocraft. Режим доступа: <https://robocraft.ru/computervision/427>.
15. Учебное пособие по фильтрам Габора. Режим доступа: <https://web.archive.org/web/20090419123314/http://mplab.ucsd.edu/tutorials/gabor.pdf>.